

Optimización de costos

Matriz de costos y optimización

Criterio general de optimización

El ecosistema fue diseñado priorizando tres variables: **costo por ejecución, velocidad de respuesta y complejidad de la tarea.**

No todas las etapas del flujo requieren un modelo de IA de alta capacidad. Por este motivo, se utiliza un modelo liviano para tareas breves y estructuradas, mientras que las operaciones que no requieren razonamiento son resueltas directamente mediante Airtable, n8n o Gmail.

La arquitectura busca evitar dos fuentes habituales de sobre costo:

- enviar información innecesaria al modelo;
- utilizar modelos de mayor capacidad para tareas simples.

Además, la base de conocimiento se consulta previamente desde Airtable, por lo que el modelo recibe únicamente el contexto relevante para la intención detectada.

Matriz de decisión

Tarea	Tecnología / Modelo	Complejidad	Justificación	Costo relativo	Decisión
Clasificación de intención	GPT-5-mini	Baja	La salida es estructurada y limitada a categorías predefinidas	Bajo	Utilizar modelo mini
Evaluación de confianza	GPT-5-mini	Baja	Forma parte de la misma clasificación y requiere poca generación	Bajo	Resolver en la misma llamada
Detección de HITL	GPT-5-mini + reglas n8n	Baja	GPT clasifica y n8n aplica reglas determinísticas	Bajo	No agregar otra llamada de IA
Consulta de conocimiento	Airtable	Baja	Es una búsqueda estructurada, no requiere razonamiento generativo	Muy bajo	Resolver sin IA
Filtrado del contexto	n8n / JavaScript	Baja	Comparación de categoría y estado activo	Muy bajo	Resolver localmente
Redacción de respuesta	GPT-5-mini	Media	Se genera una respuesta breve sobre contexto controlado	Bajo/medio	Utilizar modelo mini
Decisión final de aprobación	Humano vía Gmail	Alta criticidad	Evita automatizar acciones sensibles	Costo IA nulo	Human-in-the-loop
Envío de respuesta	Gmail	Baja	Acción transaccional sin necesidad de IA	Muy bajo	Automatización directa
Registro y auditoría	Airtable	Baja	Persistencia estructurada de resultados	Muy bajo	Automatización directa
Procesamiento masivo futuro	API Batches	Baja urgencia / alto volumen	Adecuado para operaciones que no requieren respuesta inmediata	Menor que ejecución síncrona	Considerar al escalar

Justificación del modelo utilizado

Para las tareas de **clasificación de intención** y **redacción de respuestas**, se seleccionó GPT-5-mini.

La clasificación trabaja con un conjunto reducido de categorías:

HORARIOS
PRECIOS
ACTIVIDADES
SEDES
BAJA
RECLAMO
QUEJA
COBRO
OTRO

Además, la respuesta solicitada al modelo es estructurada y de baja longitud:

```
{  
  "intencion": "HORARIOS",  
  "confianza": 0.95,  
  "requiere_humano": false,  
  "tema_conocimiento": "Horarios generales"  
}
```

Por este motivo, utilizar un modelo de mayor capacidad para esta etapa generaría un costo adicional sin aportar una mejora proporcional al resultado esperado.

La segunda llamada al modelo se utiliza únicamente para redactar una respuesta breve utilizando información obtenida previamente desde Airtable. El modelo no necesita analizar documentos extensos ni realizar razonamiento complejo, por lo que también resulta adecuado utilizar un modelo de tipo mini.

Reducción del consumo de tokens

El diseño aplica distintas estrategias para reducir el consumo de tokens.

En primer lugar, no se envía toda la base de conocimiento a OpenAI. El flujo realiza primero la siguiente secuencia:

Clasificación de intención

↓

Búsqueda en Airtable

↓

Filtrado por categoría

↓

Envío únicamente del conocimiento relevante a GPT

Por ejemplo, ante la consulta:

¿A qué hora abre el gimnasio?

el sistema no envía información de precios, bajas, cobros, actividades o reclamos.

Únicamente utiliza el registro correspondiente a:

Categoría = HORARIOS

Esto reduce la longitud del prompt y, en consecuencia, el costo de cada llamada.

En segundo lugar, la clasificación y la determinación de **requiere_humano** se realizan dentro de una misma llamada a IA, evitando ejecutar modelos adicionales para decisiones que pueden resolverse en conjunto.

Finalmente, las decisiones posteriores son implementadas mediante filtros y condiciones determinísticas de n8n, sin llamadas adicionales a un LLM.

Comparación con una arquitectura menos optimizada

Una implementación menos eficiente podría enviar en cada consulta toda la información del negocio al modelo y utilizar un modelo de alta capacidad tanto para clasificar como para responder.

Ejemplo:

Cliente



Modelo grande + base completa



Modelo grande para decidir ruta



Modelo grande para redactar



Respuesta

La arquitectura implementada reduce este esquema a:

Cliente



GPT-5-mini → Clasificación



Airtable → Contexto específico



GPT-5-mini → Redacción



n8n → Decisión automática / HITL

Por lo tanto, se reduce:

- cantidad de tokens enviados;
- cantidad de llamadas al modelo;
- uso innecesario de modelos de mayor costo;
- procesamiento de información irrelevante.

Uso de Batches ante crecimiento de volumen

Actualmente el sistema procesa consultas de forma individual porque el caso de uso requiere una respuesta cercana al tiempo real.

Sin embargo, si en el futuro existieran tareas masivas que no requieran respuesta inmediata, se podría utilizar una API de procesamiento por lotes o **Batches**.

Algunos ejemplos serían:

- reclasificación histórica de consultas;
- análisis de tendencias;
- enriquecimiento de registros antiguos;
- generación nocturna de resúmenes;
- categorización masiva de tickets.

En estos escenarios no sería necesario realizar una llamada síncrona por cada registro.

Conceptualmente:

1.000 registros

↓

Batch

↓

Procesamiento diferido

↓

Actualización masiva en Airtable

Esta estrategia permitiría disminuir el costo frente a la ejecución individual y reservar las llamadas síncronas para las interacciones que realmente requieren respuesta inmediata.

Matriz de decisión por escenario

Escenario	Estrategia elegida
Consulta individual en tiempo real	GPT-5-mini vía API síncrona
Clasificación estructurada	GPT-5-mini
Generación de respuesta breve	GPT-5-mini
Consulta de información del negocio	Airtable, sin IA
Reglas de decisión	n8n, sin IA
Acción sensible	HITL
Miles de registros sin urgencia	Batches
Lectura futura de documentación extensa	Evaluar un modelo de mayor capacidad únicamente si la complejidad lo justifica

Ahorro estimado por diseño

El principal ahorro del ecosistema no proviene únicamente de seleccionar un modelo más económico, sino de **reducir la cantidad de información y llamadas que requieren IA**.

Por cada consulta normal se realizan, como máximo, dos operaciones principales con el LLM:

1 llamada → clasificación

1 llamada → redacción

La búsqueda de conocimiento, validaciones, decisión de rutas, actualización de estados, registro de logs y envío de emails se realizan sin utilizar modelos generativos.

Una arquitectura alternativa podría utilizar IA para varias de estas decisiones, aumentando innecesariamente el número de llamadas por consulta.

Por lo tanto, el ahorro estimado puede expresarse de forma conceptual como:

Costo optimizado

=

2 llamadas breves de IA

+

operaciones determinísticas

vs.

Costo no optimizado

=
múltiples llamadas de IA
+
contexto completo
+
modelo de mayor tamaño

En escenarios de alto volumen, esta diferencia se vuelve especialmente significativa.

Conclusión

La estrategia de costos busca aplicar IA únicamente donde aporta valor.

GPT se utiliza para las tareas que requieren interpretación de lenguaje natural:

- comprender la intención;
- estimar confianza;
- redactar una respuesta.

El resto del proceso se resuelve mediante herramientas determinísticas como Airtable, n8n y Gmail.

Esto permite obtener un sistema más económico, auditable y escalable, manteniendo la posibilidad de incorporar modelos de mayor capacidad o procesamiento por Batches únicamente cuando el volumen o la complejidad lo justifiquen.